

物体検知輪読#3

Vision Transformer

工学部情報学科2回

知能太郎

■ アジェンダ

- 1. 研究背景
- 2. 解決したい課題
- 3. 提案手法の全体像
- 4. 手法の詳細と数式
- 5. 実験・結果・考察・まとめ

— 研究背景

NLPではTransformerが標準になった一方、画像認識ではCNNが長く主流だった。

NLP側の成功

- Transformerは大規模事前学習とfine-tuningで高性能を示した
- BERTやGPT系のように、事前学習済み表現を転移する流れが強い
- モデルとデータを大きくしても性能が伸び続けた

画像認識側の状況

- ResNet系の畳み込みネットワークが強い
- 局所性や平行移動等価性が画像に合っていた
- 自己注意はCNNと組み合わせる研究が多かった

ViTは、CNNに依存せず標準Transformerを画像分類へ直接使えるかを検証する。

— 解決したい課題

画像をTransformerへ入れるには、2次元画像を1次元トークン列として扱う必要がある。

技術的な課題

- Transformerは1D系列のtoken embeddingsを入力にする
- 画像は2D構造と局所性を持つ
- 画像固有の帰納バイアスを減らすとデータ要求が大きくなる

論文の問い

- 画像を単語列のように扱えるか
- 標準Transformer encoderだけで画像分類できるか
- 大規模事前学習でCNNとの差を埋められるか

中規模データではResNetに劣るが、大規模事前学習で状況が変わる、という仮説が中心になる。

— 提案手法の全体像

ViTは画像を固定サイズのパッチに分け、それぞれをTransformerの入力トークンとして扱う。

入力側

- パッチはNLPの単語tokenに対応
- 各パッチを同じ次元のベクトルへ写像
- 先頭に分類用のlearnable tokenを追加

モデル側

- Transformer encoderはほぼ標準形
- 画像固有の処理は入力変換に集中
- 最後のclass tokenを画像表現として使う

**[ここに論文Figure 1: Model overview。Image -> Patches -> Transformer Encoder
の全体図を入れる]**

— 手法の詳細1

2次元画像をパッチ列へ変換し、位置情報を足してTransformerへ入力する。

パッチ数

画像サイズを $H \times W$ 、パッチサイズを $P \times P$ とすると、パッチ数 N は次で決まる。

$$N = \frac{HW}{P^2}$$

- H, W : 入力画像の高さと幅
- P : 1パッチの一辺
- N : Transformerへ入る画像パッチの個数

パッチサイズを小さくすると系列長が増え、計算量は増えるが細かい情報を扱いやすくなる。

— 手法の詳細1: 初期系列

class token、パッチ埋め込み、位置埋め込みを足してTransformerの入力系列を作る。

$$z_0 = [x_{\text{class}}; e_1; \dots; e_N] + E_{\text{pos}}$$

- z_0 : Transformer Encoderへ入力する最初のtoken列
- x_{class} : 画像全体の表現を集約するclass token
- e_i : i 番目の画像パッチを線形射影した埋め込み
- E_{pos} : 各tokenの位置を表す位置埋め込み

— 手法の詳細2: Encoder

各層では、LayerNorm、Multi-head Self-Attention、MLP、残差接続を交互に使う。

$$u_{\ell} = \text{MSA}(\text{LN}(z_{\ell-1})) + z_{\ell-1}$$

$$z_{\ell} = \text{MLP}(\text{LN}(u_{\ell})) + u_{\ell}$$

LN

各blockの前に適用

MSA

全パッチ間を学習

MLP

各tokenを変換

Residual

各block後に足し戻す

- $z_{\ell-1}$: 前層から渡される入力表現
- u_{ℓ} : Self-Attention後の中間表現
- z_{ℓ} : MLP後に次層へ渡される出力表現
- LN, MSA, MLP: LayerNorm、Multi-head Self-Attention、MLPを表す

— 実験設定

ViTは大規模データで事前学習し、小さめの下流データセットへ転移する設計で評価される。

事前学習データ

- ImageNet: 1.3M images
- ImageNet-21k: 14M images
- JFT-300M: 303M high-resolution images

転移評価

- ImageNet / ImageNet-Real
- CIFAR-10 / CIFAR-100
- Oxford Pets, Flowers, VTAB

比較では、ResNetベースのBiTやNoisy Studentなど当時の強いCNN系モデルも参照される。

— 結果

十分な規模で事前学習したViTは、複数の画像認識ベンチマークで高い性能を示した。

[ここに論文Table 2: popular image classification benchmarks の比較表を入れる]

表で見る点

- ImageNet、CIFAR-100、VTABなどで比較する
- ViT-L/16とBiT-Lなど強いCNN系を比べる
- 平均値と標準偏差で性能を報告する

主な読み取り

- JFT-300M事前学習でViTは高い転移性能を示す
- 大規模データではCNN系baselineを上回る
- 精度だけでなく事前学習コストも議論される

— 考察

ViTの弱点は画像固有の帰納バイアスが少ないことだが、その分スケールしたときの伸びが大きい。

小さい事前学習

- ImageNetのみでは大きなViTがResNetより不利
- データ不足では帰納バイアスの少なさが弱点になる
- 空間関係をデータから学ぶ必要がある

大きい事前学習

- ImageNet-21kで性能差が縮まる
- JFT-300Mでは大きなViTが強くなる
- ResNetは早めに頭打ちになり、ViTは伸び続ける

[ここに論文Figure 3/5: 事前学習データ規模・計算量と転移性能の関係を入れる]

— 限界・今後の課題

ViTは強力だが、十分なデータと計算資源が前提になりやすい。

限界

- 中規模データだけではCNNに劣る場合がある
- 系列長が長くなると計算量が増える
- 画像の2D構造は主にパッチ分割と位置埋め込みに限られる

今後の方向

- 自己教師あり事前学習の改善
- より効率的な視覚Transformer
- 階層構造や局所性を取り入れた発展モデル

ViT以後、SwinやConvNeXtのように、TransformerとConvNetの設計を再検討する流れが強まった。

— まとめ

ViTは、画像をパッチ列として扱うことでTransformerを画像分類へ直接適用した。

背景

NLPで成功したTransformerを、CNN優勢の画像認識へ持ち込む。

方法

画像を固定サイズパッチに分け、位置埋め込み付きのtoken列として処理する。

結論

大規模事前学習後の転移では、強いCNN系baselineに匹敵または上回る。

輪読では「画像を16x16 wordsとして読むTransformer」と捉えると、論文の流れを追やすい。