



論文紹介 2026/05/21

ResNet

同志社大学 工学部

銅 使者

- 1. 研究背景と課題
- 2. 提案手法：深層残差学習
- 3. 実験と結果
- 4. 考察とまとめ

— 背景：深層化による性能向上とその限界

ネットワークを深く（Deepに）することで性能は向上するはずでした

深層化のトレンド

- VGGネットに代表されるように、層を深くすることでモデルの表現力が向上し、精度が改善されるのが一般的でした。

[図: VGGネットのような層が積み重なったネットワークのイメージ図]

層を増やすほど性能は上がるはずが…

深層化の障壁

- **勾配消失/爆発問題**
 - 学習が不安定になる問題。バッチ正規化(BN)等で緩和。
- **Degradation (劣化) 問題**

— 解決したい課題：Degradation（劣化）問題

単純に層を深くすると、性能が劣化してしまう現象

- 理論上、深いモデルは浅いモデルに「何もしない層」を追加すれば、少なくとも同等以上の性能は出せるはずです。
- しかし、最適化が困難なため、実際には**深いモデルの方が訓練誤差が悪化**します。
- これは過学習ではなく、**最適化の難しさ**が原因と考えられます。

[図: 論文Figure 1。20層と56層のPlain Netの誤差グラフ]

56層ネットワーク（深い）は20層（浅い）より誤差が大きい

— 提案手法：深層残差学習 (Deep Residual Learning)

出力そのものではなく、**残差 (Residual)** を学習させます
あるべき写像を $H(x)$ とします。

従来のネットワークでは、入力 x から $H(x)$ を直接学習しようとしています。

$$H(x)$$

本研究では、学習対象を**残差** $F(x) = H(x) - x$ と再定義します。

$$F(x) := H(x) - x$$

これにより、ネットワークは元の写像 $H(x)$ を $F(x) + x$ として学習します。

$$H(x) = F(x) + x$$

このアイデアが、深いネットワークの学習を劇的に容易にします。

— 提案手法の中核：残差ブロック

入力をバイパスする「ショートカットコネクション」を追加します

[図: 論文Figure 2。残差ブロックの概念図]

なぜうまくいくのか？

- もし追加層が「何もしない」のが最適な場合、従来のネットワークは恒等写像 $H(x)=x$ を学習する必要があり、これは困難です。
- 一方、残差学習では残差 $F(x)$ がゼロになるように学習すればよいだけです。
- 重みをゼロに近づけるだけで済むため、学習が非常に容易になり、Degradation問題を回避できます。

— ResNetアーキテクチャ

VGGベースのPlain Netにショートカットを追加した構成

Plain Network (34層)

[図: 論文Figure 3 Middle。34層Plain Netの構成図]

Residual Network (34層)

[図: 論文Figure 3 Right。34層ResNetの構成図。ショートカットが追加されている]

- ResNetは、同じ層数のPlain Netに

ショートカットコネクションを追加

しただけのシンプルな構造です。 - これにより、深層化による性能劣化を防ぎます。

— 実験設定

ショートカットコネクションの効果を直接比較します

- データセット

- 画像分類: ImageNet 2012, CIFAR-10
- 物体検出: PASCAL VOC, MS COCO

- 比較対象

- **Plain Network**: ResNetと同じ層数・構造だが**ショートカットがない**ネットワーク。Degradation問題を再現し、ResNetの効果を直接比較するために使用。
- **既存SOTAモデル**: VGG, GoogLeNetなど。

- 評価

- 18層から152層までのPlain NetとResNetを比較します。
- CIFAR-10では1000層を超えるネットワークも試行します。

— 結果1: Degradation問題の解決

ResNetは深くなるほど一貫して性能が向上しました

[図: 論文Figure 4. Plain NetとResNetの訓練・検証誤差グラフの比較]

Plain Network

- 34層（深い）は18層（浅い）より誤差が悪化。Degradation問題を再現。

Residual Network (ResNet)

- 34層は18層より誤差が改善。深さの恩恵を享受。

残差学習が、深いネットワークの最適化を効果的に容易にすることを示しています。

— 結果2: ImageNetでの驚異的な性能

152層ResNetがILSVRC 2015で優勝しました

- ResNetは層を深くするほど精度が向上し、152層モデルで最高性能を達成。
- アンサンブルモデルは**Top-5エラー率3.57%**を記録し、当時のSOTAを大幅に更新しました。

[図: 論文Table 4の主要部分を抜粋した表。ResNet-152の圧倒的な性能を示す]

モデル	Top-5 エラー率 (%)
VGG-16 [41]	7.1
PreLU-net [13]	5.71
ResNet-34 B	5.71
ResNet-101	4.60
ResNet-152	3.57

— 結果3: 学習された特徴の汎用性

物体検出タスクでも性能が大幅に向上しました

- 物体検出のバックボーンをVGG-16からResNet-101に置き換えるだけで、MS COCOデータセットでの性能が飛躍的に向上しました。
- mAP@.5:.95 (標準指標) で**28%の相対的改善**を達成。
- この結果は、ResNetがタスクに依存しない、より高品質で汎用的な特徴を学習できていることを示しています。

[図: 論文Table 8を元にした比較表]

バックボーン	mAP @ [.5, .95]	mAP @ .5
VGG-16	21.2	41.5
ResNet-101	27.2	48.4
向上率	+28%	+17%

— 考察：残差は本当に学習されているか？

ResNetの層の応答は、Plain Netより小さい傾向にあります

[図: 論文Figure 7。各層の出力の標準偏差を示すグラフ]

- ResNetの層の応答（ $\equiv$ 学習された残差 $F(x)$ の大きさ）は、Plain Netに比べて全体的に小さいことがわかります。
- 特に深いResNet（110層）ほど、応答が小さくなる傾向があります。
- これは、多くの層が恒等写像に近い、つまり「**何もしない**」に近い振る舞いをしてい**る**ことを示唆しており、残差学習の仮説を裏付けています。

— まとめ

本研究の貢献

Degradation問題を解決する「深層残差学習」を提案

ショートカットコネクションにより、超深層ネットワークの最適化を可能にしました。

152層の超深層モデルでSOTAを達成

ImageNetコンペで優勝し、深層学習の性能を新たな次元へと引き上げました。

現代の深層学習モデルの基礎を構築

ResNetは画像認識だけでなく、物体検出など多くのタスクの標準的なバックボーンとなり、その後の研究に絶大な影響を与えました。