

2024年度後期輪読会 #3 (2024/10/17)

Swin Transformer, Swin Transformer V2

京都大学工学部理工化学科1回生

岡本 和優

- Swin Transformer
- Swin Transformer V2

- Swin Transformer
- Swin Transformer V2

Swin Transformer

Vision Transformerの問題点

Vision Transformerには次の2つの問題点がある。


- 問題点1：画像を特定サイズのパッチに分割しているため、
物体スケールの変化が捉えられない。
 - 物体検出では画像において異なった大きさで現れる対象を認識する必要がある。
- 問題点2：画像の解像度が高くなると計算量が増える。
 - これはSelf-Attentionの計算量がパッチ数の2乗に依拠して大きくなることが原因。
 - 画像認識では高解像度の画像を扱うことが多いが、このままでは扱えない。

Swin Transformer

Swin Transformerでの改善点

Swin Transformerは前述の問題点を次のようにして改善した。

- 改善点1：パッチサイズを段階的に変化させていく。
- 改善点2：Self-Attentionを画像全体ではなく、限られたWindow内のみに適用する。



パッチ（灰枠）サイズを変化させながら，Window（赤枠）内でのみSelf-Attentionを計算。

Swin Transformer

Swin Transformerのアーキテクチャ

Vision Transformerからの主な改善点は次の2つ。

- Patch Merging :
特徴マップのサイズを段階的に変化させる。
- Swin Transformer Block :
W-MSAとSW-MSA（後述）を交互に適用。それ以外は通常のTransformer。




Figure 3. (a) The architecture of a Swin Transformer (Swin-T); (b) two successive Swin Transformer Blocks (notation presented with Eq. (3)). W-MSA and SW-MSA are multi-head self attention modules with regular and shifted windowing configurations, respectively.


Swin Transformer

Patch Partition, Linear Embedding

- Patch Partition :
ViTと同様に画像を固定サイズ（デフォルトは 4×4 ）のパッチに分割する。
- Linear Embedding :
パッチ特徴量を $4 \times 4 \times 3 = 48$ 次元から C 次元に変換する。

実際には2つをまとめて $\text{kernel_size}=\text{stride}=\text{パッチサイズ}$ のconv2dで行っている。

図 6.4 : Patch Partition と Linear Embedding の概略図



図は[Vision Transformer入門](#)から。

Swin Transformer


Patch Merging

近傍 2×2 のパッチ特徴量をチャンネル方向に結合することで、特徴マップのサイズを縮小し、それにより得られた $4C$ 次元の特徴量を全結合層により $2C$ 次元に変換する。

これにより1つのパッチがより広範囲の特徴を得る（パッチを大きくすることに相当）。

Swin TransformerではPatch Mergingを重ねることで、特徴マップを最終的に $H/32 \times W/32$ ピクセルにまで縮小する。このときパッチ特徴量は $8C$ 次元。

図6.5：Patch Mergingの概略図（Stage2の処理例）



図は[Vision Transformer入門](#)から。


Swin Transformer

Swin Transformer Block

基本的には通常のTransformerと同じ。

W-MSA (Window-Based Multi-head Self-Attention) と,
SW-MSA (Shifted Window-Based Multi-head Self-Attention) を交互に適用している。

$$\begin{aligned}\hat{z}^l &= W\text{-MSA}\left(LN(z^{l-1})\right) + z^{l-1}, \\ z^l &= MLP\left(LN(\hat{z}^l)\right) + \hat{z}^l, \\ \hat{z}^{l+1} &= SW\text{-MSA}\left(LN(z^l)\right) + z^l, \\ z^{l+1} &= MLP\left(LN(\hat{z}^{l+1})\right) + \hat{z}^{l+1}\end{aligned}$$



Swin Transformer

Window-based Multi-head Self-Attention (W-MSA)

特徴マップを $M \times M$ の Window で分割し、
Window 内のパッチでのみ Self-Attention を計算する。
このとき計算量は次のように削減される。

$h \times w$ 個のパッチがあるとき、Self-Attention 全体の
計算量は下のようになる。


$$\Omega(MSA) = 4hwc^2 + 2(hw)^2c$$

第1項はクエリ・キー・バリューの計算と、
最後の線形変換を行う計4つの全結合層の計算量で、
第2項はクエリとキーの間の行列積に必要な計算量。
このとき計算量は $(hw)^2$ に応じて大きくなってしまう。

一方 $M \times M$ の Window 内のみで Self-Attention を行う
場合の計算量は、

$$\Omega(W-MSA) = 4hwc^2 + 2M^2hwc$$

となり、 M を固定（デフォルトは7）したとき
計算量は hw に従う。



Swin Transformer

Shifted-Window-based Multi-head Self-Attention (SW-MSA)



Windowを $\left(\left\lceil \frac{M}{2} \right\rceil, \left\lceil \frac{M}{2} \right\rceil\right)$ ピクセル移動させてW-MSAを行う。

しかし, Windowを単に移動するだけだと,
Window数が増えて $M \times M$ より小さいWindowができる。
パディングでWindowのサイズを揃えても計算量が増える。



そこで, 特徴マップにcyclic shiftを行い, 実際は隣接しない複数のWindowが含まれるWindowにはマスキングを施し, 異なるWindow間のAttentionを0にすることで効率的に計算を行っている。

Windowではなく特徴マップを動かすことで,
Windowのサイズと数を計算上は固定している。



Swin Transformer

Relative position bias


Swin TransformerはViTと異なり、
各パッチ特徴量に絶対的な位置情報は付与しない。

その代わりにRelative position bias : B を用いることで、
Self-Attentionの計算のときWindow内の相対的な位置関係
に応じてAttentionの重みを調整している。

$$Attention(Q, K, V) = SoftMax\left(\frac{QK^T}{\sqrt{d}} + B\right)V$$

$M \times M$ のWindow内での相対的な位置関係は縦横 $[-M + 1, M - 1]$
の範囲（右端から見た左端～左端から見た右端，までの範囲）
にあるから， B は $(2M - 1)^2$ 通りになる。

図 6.8 : Relative Posion Biasの概略図。強調されたパッチを基準に他のパッチ
間との相対的な位置関係を表す



図は[Vision Transformer入門](#)から。

Swin Transformer

クラス分類の実験結果

(a) Regular ImageNet-1K trained models					
method	image size	#param.	FLOPs	throughput (image / s)	ImageNet top-1 acc.
RegNetY-4G [48]	224 ²	21M	4.0G	1156.7	80.0
RegNetY-8G [48]	224 ²	39M	8.0G	591.6	81.7
RegNetY-16G [48]	224 ²	84M	16.0G	334.7	82.9
EffNet-B3 [58]	300 ²	12M	1.8G	732.1	81.6
EffNet-B4 [58]	380 ²	19M	4.2G	349.4	82.9
EffNet-B5 [58]	456 ²	30M	9.9G	169.1	83.6
EffNet-B6 [58]	528 ²	43M	19.0G	96.9	84.0
EffNet-B7 [58]	600 ²	66M	37.0G	55.1	84.3
ViT-B/16 [20]	384 ²	86M	55.4G	85.9	77.9
ViT-L/16 [20]	384 ²	307M	190.7G	27.3	76.5
DeiT-S [63]	224 ²	22M	4.6G	940.4	79.8
DeiT-B [63]	224 ²	86M	17.5G	292.3	81.8
DeiT-B [63]	384 ²	86M	55.4G	85.9	83.1
Swin-T	224 ²	29M	4.5G	755.2	81.3
Swin-S	224 ²	50M	8.7G	436.9	83.0
Swin-B	224 ²	88M	15.4G	278.1	83.5
Swin-B	384 ²	88M	47.0G	84.7	84.5

(b) ImageNet-22K pre-trained models					
method	image size	#param.	FLOPs	throughput (image / s)	ImageNet top-1 acc.
R-101x3 [38]	384 ²	388M	204.6G	-	84.4
R-152x4 [38]	480 ²	937M	840.5G	-	85.4
ViT-B/16 [20]	384 ²	86M	55.4G	85.9	84.0
ViT-L/16 [20]	384 ²	307M	190.7G	27.3	85.2
Swin-B	224 ²	88M	15.4G	278.1	85.2
Swin-B	384 ²	88M	47.0G	84.7	86.4
Swin-L	384 ²	197M	103.9G	42.1	87.3

- CNNと比較して精度と速度のトレードオフが少し改善。
- RegNetやEfficientNetはアーキテクチャの探索の末に得られたものだが、Swin Transformerは標準的なTransformerを用いているだけだから改善の余地あり。

Swin Transformer

物体検出の実験結果

(a) Various frameworks							
Method	Backbone	AP ^{box}	AP ^{box} ₅₀	AP ^{box} ₇₅	#param.	FLOPs	FPS
Cascade	R-50	46.3	64.3	50.5	82M	739G	18.0
Mask R-CNN	Swin-T	50.5	69.3	54.9	86M	745G	15.3
ATSS	R-50	43.5	61.9	47.0	32M	205G	28.3
	Swin-T	47.2	66.5	51.3	36M	215G	22.3
RepPointsV2	R-50	46.5	64.6	50.3	42M	274G	13.6
	Swin-T	50.0	68.5	54.2	45M	283G	12.0
Sparse R-CNN	R-50	44.5	63.4	48.2	106M	166G	21.0
	Swin-T	47.9	67.3	52.3	110M	172G	18.4

(b) Various backbones w. Cascade Mask R-CNN								
	AP ^{box}	AP ^{box} ₅₀	AP ^{box} ₇₅	AP ^{mask}	AP ^{mask} ₅₀	AP ^{mask} ₇₅	#param	FLOPs/FPS
DeiT-S [†]	48.0	67.2	51.7	41.4	64.2	44.3	80M	889G 10.4
R50	46.3	64.3	50.5	40.1	61.7	43.4	82M	739G 18.0
Swin-T	50.5	69.3	54.9	43.7	66.6	47.1	86M	745G 15.3
X101-32	48.1	66.5	52.4	41.6	63.9	45.2	101M	819G 12.8
Swin-S	51.8	70.4	56.3	44.7	67.9	48.5	107M	838G 12.0
X101-64	48.3	66.4	52.3	41.7	64.0	45.1	140M	972G 10.4
Swin-B	51.9	70.9	56.5	45.0	68.4	48.7	145M	982G 11.6

(c) System-level Comparison						
Method	mini-val		test-dev		#param.	FLOPs
	AP ^{box}	AP ^{mask}	AP ^{box}	AP ^{mask}		
RepPointsV2* [12]	-	-	52.1	-	-	-
GCNet* [7]	51.8	44.7	52.3	45.4	-	1041G
RelationNet++* [13]	-	-	52.7	-	-	-
SpineNet-190 [21]	52.6	-	52.8	-	164M	1885G
ResNeSt-200* [78]	52.5	-	53.3	47.1	-	-
EfficientDet-D7 [59]	54.4	-	55.1	-	77M	410G
DetectoRS* [46]	-	-	55.7	48.5	-	-
YOLOv4 P7* [4]	-	-	55.8	-	-	-
Copy-paste [26]	55.9	47.2	56.0	47.4	185M	1440G
X101-64 (HTC++)	52.3	46.0	-	-	155M	1033G
Swin-B (HTC++)	56.4	49.1	-	-	160M	1043G
Swin-L (HTC++)	57.1	49.5	57.7	50.2	284M	1470G
Swin-L (HTC++)*	58.0	50.4	58.7	51.1	284M	-

Swin Transformer

セマンティックセグメンテーションの実験結果

ADE20K		val	test	#param.	FLOPs	FPS
Method	Backbone	mIoU	score			
DANet [23]	ResNet-101	45.2	-	69M	1119G	15.2
DLab.v3+ [11]	ResNet-101	44.1	-	63M	1021G	16.0
ACNet [24]	ResNet-101	45.9	38.5	-		
DNL [71]	ResNet-101	46.0	56.2	69M	1249G	14.8
OCRNet [73]	ResNet-101	45.3	56.0	56M	923G	19.3
UperNet [69]	ResNet-101	44.9	-	86M	1029G	20.1
OCRNet [73]	HRNet-w48	45.7	-	71M	664G	12.5
DLab.v3+ [11]	ResNeSt-101	46.9	55.1	66M	1051G	11.9
DLab.v3+ [11]	ResNeSt-200	48.4	-	88M	1381G	8.1
SETR [81]	T-Large [‡]	50.3	61.7	308M	-	-
UperNet	DeiT-S [†]	44.0	-	52M	1099G	16.2
UperNet	Swin-T	46.1	-	60M	945G	18.5
UperNet	Swin-S	49.3	-	81M	1038G	15.2
UperNet	Swin-B [‡]	51.6	-	121M	1841G	8.7
UperNet	Swin-L [‡]	53.5	62.8	234M	3230G	6.2

Swin Transformer

Ablation Study

Shifted windows, Relative position biasを用いたときの方が性能が高い。

	ImageNet		COCO		ADE20k
	top-1	top-5	AP ^{box}	AP ^{mask}	mIoU
w/o shifting	80.2	95.1	47.7	41.5	43.3
shifted windows	81.3	95.6	50.5	43.7	46.1
no pos.	80.1	94.9	49.2	42.6	43.8
abs. pos.	80.5	95.2	49.0	42.4	43.2
abs.+rel. pos.	81.3	95.6	50.2	43.4	44.0
rel. pos. w/o app.	79.3	94.7	48.2	41.9	44.1
rel. pos.	81.3	95.6	50.5	43.7	46.1

- Swin Transformer
- Swin Transformer V2


Swin Transformer V2

Swin Transformerからの変更点

Swin Transformerからの主な変更点は以下の3つ。

- Layer Normalizationの位置を変更。
- Attentionのとき単に内積を取るのではなく、学習可能なパラメータ τ でスケールする。
- MLPを用いてRelative Position Biasを生成する。
 - ここでは相対位置を対数でスケールしている。

これらの工夫で、モデルを大きくすることに成功した。




Swin Transformer V2


Post normalization

post-normに変更することで、層が深くなるにつれて活性化の値が大きくなってしまいう問題を解消している。

各層で活性化の値の大きさに差があると学習が不安定になる。



post-norm場合は層が深くなっても、分散が大きくなりにくい。



pre-normだと学習ができないこともある。

Swin Transformer V2

Scaled cosine attention

特にpost-normの場合は、一部のピクセルの組が全体に大きな影響を与えてしまうことが多い。
この問題を緩和するために、Scaled cosine attentionが用いられている。

$$\text{Sim}(\mathbf{q}_i, \mathbf{k}_j) = \cos(\mathbf{q}_i, \mathbf{k}_j) / \tau + B_{ij}$$

τ は0.01以上の学習化なスケーラーで、それぞれのヘッドとレイヤーで独立している。

コサインで正規化されているため、Attentionの値が極端にならない。

Swin Transformer V2

Continuous relative position bias

Relative Position Bias : B を直接最適化せずに, MLP (デフォルトではReLUを挟んで2層) を用いてこれを生成する。

$$B(\Delta x, \Delta y) = g(\Delta x, \Delta y)$$

g は任意の相対位置に対し連続的に B を生成できるため, Windowサイズの変化に対応できる。

ただし, Windowサイズを大きく変化させる場合 (小さいWindowの事前学習モデルから大きいWindowのモデルにFine-tuningするとき) のために, 相対位置の座標を下のように対数を用いてスケールしている (Log-spaced coordinates) 。

$$\begin{aligned}\widehat{\Delta x} &= \text{sign}(x) \cdot \log(1 + |\Delta x|), \\ \widehat{\Delta y} &= \text{sign}(y) \cdot \log(1 + |\Delta y|)\end{aligned}$$

Swin Transformer V2

クラス分類の実験結果

SwinV2-Gではパラメータ数を30億にまで増やしている。

他の大規模なモデルと比較して、少ない学習回数と低い解像度でそれなりの精度を実現。

Method	param	pre-train images	pre-train length (#im)	pre-train im size	pre-train time	fine-tune im size	ImageNet-1K-V1 top-1 acc	ImageNet-1K-V2 top-1 acc
SwinV1-B	88M	IN-22K-14M	1.3B	224 ²	<30 [†]	384 ²	86.4	76.58
SwinV1-L	197M	IN-22K-14M	1.3B	224 ²	<10 [†]	384 ²	87.3	77.46
ViT-G [80]	1.8B	JFT-3B	164B	224 ²	>30k	518 ²	90.45	83.33
V-MoE [56]	14.7B*	JFT-3B	-	224 ²	16.8k	518 ²	90.35	-
CoAtNet-7 [17]	2.44B	JFT-3B	-	224 ²	20.1k	512 ²	90.88	-
SwinV2-B	88M	IN-22K-14M	1.3B	192 ²	<30 [†]	384 ²	87.1	78.08
SwinV2-L	197M	IN-22K-14M	1.3B	192 ²	<20 [†]	384 ²	87.7	78.31
SwinV2-G	3.0B	IN-22K-ext-70M	3.5B	192 ²	<0.5k [†]	640 ²	90.17	84.00

Swin Transformer V2

物体検出, セマンティックセグメンテーションの実験結果

Method	train	test	mini-val (AP)		test-dev (AP)	
	I(W) size	I(W) size	box	mask	box	mask
CopyPaste [25]	1280(-)	1280(-)	57.0	48.9	57.3	49.1
SwinV1-L [46]	800(7)	ms(7)	58.0	50.4	58.7	51.1
YOLOR [66]	1280(-)	1280(-)	-	-	57.3	-
CBNet [43]	1400(7)	ms(7)	59.6	51.8	60.1	52.3
DyHead [16]	1200(-)	ms(-)	60.3	-	60.6	-
SoftTeacher [74]	1280(12)	ms(12)	60.7	52.5	61.3	53.0
SwinV2-L (HTC++)	1536(32)	1100(32)	58.8	51.1	-	-
		1100 (48)	58.9	51.2	-	-
		ms (48)	60.2	52.1	60.8	52.7
SwinV2-G (HTC++)	1536(32)	1100(32)	61.7	53.3	-	-
		1100 (48)	61.9	53.4	-	-
		ms (48)	62.5	53.7	63.1	54.4

物体検出

Method	train I(W) size	test I(W) size	mIoU
SwinV1-L [46]	640(7)	640(7)	53.5*
Focal-L [75]	640(40)	640(40)	55.4*
CSwin-L [21]	640(40)	640(40)	55.7*
MaskFormer [13]	640(7)	640(7)	55.6*
FaPN [33]	640(7)	640(7)	56.7*
BEiT [4]	640(40)	640(40)	58.4*
SwinV2-L (UperNet)	640(40)	640(40)	55.9*
SwinV2-G (UperNet)	640(40)	640(40)	59.1
		896 (56)	59.3
		896 (56)	59.9*

セマンティックセグメンテーション

Swin Transformer V2

Ablation Study

post-normやscaled cosine attentionにより性能が改善している。

Log-spaced coordinatesは、Fine-Tuning前後で
画像サイズやWindowのサイズの差が大きくなるほど効果が顕著。

Backbone	res-post-norm	scaled cosine attention	ImageNet top-1 acc
Swin-T			81.5
	✓		81.6
	✓	✓	81.7
Swin-S			83.2
	✓		83.3
	✓	✓	83.6
Swin-B			83.6
	✓		83.8
	✓	✓	84.1
ViT-B			82.2
	✓	✓	82.6

Backbone	L-CPB	ImageNet*	ImageNet [†]	
		W8, I256	W12, I384	W16, I512
SwinV2-S		83.7	81.8/84.5	79.4/84.9
	✓	83.7	84.1/84.8	82.9/85.4
SwinV2-B		84.1	82.9/85.0	81.0/85.3
	✓	84.2	84.5/85.1	83.8/85.6

まとめ

Swin Transformer, Swin Transformer V2のまとめ

- Swin Transformerは, Vision Transformerを物体スケールの変化を捉え, 高解像度の画像を処理することができるよう改良したもの。
 - Patch mergingでパッチサイズを段階的に変化。
 - Shifted windows内でのみAttentionを計算。
- Swin Transformer V2は, Swin Transformerをモデルが大きくなるよう改良したもの。
 - post-norm, Scaled cosine attentionにより活性化の値を抑える。
 - Continuous relative position biasによりWindowサイズの拡大に対応。

参考文献

参考にした文献やページの一覧

- [\[2103.14030\] Swin Transformer: Hierarchical Vision Transformer using Shifted Windows \(arxiv.org\)](#)
- [\[2111.09883\] Swin Transformer V2: Scaling Up Capacity and Resolution \(arxiv.org\)](#)
- [Vision Transformer入門](#)
- [Swin Transformer \(ICCV'21 Best Paper\) を完璧に理解する資料 | PPT \(slideshare.net\)](#)
- [【論文5分まとめ】 Swin Transformer \(zenn.dev\)](#)
- [\[論文メモ\] Swin Transformer V2: Scaling Up Capacity and Resolution - にんひどりんはんのう \(hatenablog.com\)](#)