

2024年度後期輪読会#9(2024/12/12)

YOLO 原論文

最上 勇登

- YOLO(初代)とは
- YOLOの学習と推論
- 他手法との比較

YOLO(You Only Look Once)とは

YOLOとは？

2015年に発表された新しい物体検出の手法。名称はyou only live once(人生は一度きり)から。

従来手法：

- スライディングウィンドウアプローチ(DPMなど):
分類器を様々な位置と大きさ順番に画像に適用する。
- 分割手法(R-CNNなど):
バウンディングボックスを推定した後に分類器を適用する。構造が複雑で速度が遅く、
個々のコンポーネントを別々に最適化する必要がある。

YOLO:


画像全体から直接バウンディングボックスの座標とクラス確率の両方を予測するニューラルネットワークを学習。背景のコンテキストや一般化能力が向上。

YOLOは物体検出の各要素(特徴抽出、バウンディングボックス予測、分類など)を単一のニューラルネットワークで内包している。

- 画像を $S \times S$ のグリッドに分割し、各グリッドセルが B 個のバウンディングボックスとそれぞれの信頼度スコアを予測する。
- 各グリッドセルは C 個のクラス確率をそれぞれ予測
- 最終的な出力は $S \times S \times (B \times 5 + C)$ のテンソル
- 5は各bboxに対する(x, y, w, h, confidence)を示す

- PASCAL VOCデータセットでは、 $S=7$ 、 $B=2$ 、 $C=20$ と設定され、最終的な出力形状は $(7 \times 7 \times (2 \times 5 + 20))$ 。
それぞれ(grid × grid × (bbox × prams) + num of class)を表す。
- 最終出力は $49 \times [x,x,x,x,x, x,x,x,x,x, x,x,x,x,x,x,x,x,x,x,x,x,x,x,x,x,x]$

YOLOの検出手法



$[obj_name, x_{min}, y_{min}, x_{max}, y_{max}]$



$[obj_name, center_x, center_y, w, h]$

simple

引
用:<https://medium.com/@sachinsoni600517/concept-of-yolov1-the-evolution-of-real-time-object-detection-d773770ef773>

YOLOは物体検出の各要素(特徴抽出、バウンディングボックス予測、分類など)を単一のニューラルネットワークで内包している。

- **畳み込み層**：24層の畳み込み層で特徴抽出
- **全結合層**：2層の全結合層で最終的な予測を出力
- 1×1の縮小層と3×3の畳み込み層を交互に使用。ダウンサンプリングが多く、特徴マップが大きくなりすぎないため高速

- 畳み込み層を9層に減らし、フィルター数も削減。

- YOLO(初代)とは
- **YOLOの学習と推論**
- 他手法との比較

YOLOの学習

学習

事前学習: 最初の20層にpooling層と全結合層を追加して、1000クラスのImageNetで事前学習。

学習: 畳み込みを4層追加して2層の全結合層に置換。入力解像度を224→448に変更。(検出タスクのため)

正規化:

- **幅と高さ(w, h)の正規化:**

bboxの幅と高さを画像全体の幅と高さで割り、0から1の範囲に正規化。

- **中心座標(x, y):**

各グリッドセル左上を(0,0)としたオフセットとして予測。0から1の範囲。

活性化関数:

- **最終層:** 線形活性化層でそのまま出力
- **その他の層:** Leaky ReLU: $\Phi(\text{gain } 0.1)$

$$\phi(x) = \begin{cases} x, & \text{if } x > 0 \\ 0.1x, & \text{otherwise} \end{cases}$$

YOLOの学習

損失関数

損失関数は**多項目の二乗誤差**。項目はbbox位置, 信頼度スコア, クラス確率。
幅wと高さhは平方根をとって、小さいbboxが重要視されるようにしている。

loss function:

$$\begin{aligned} & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\ & + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$

- $\lambda_{\text{coord}} = 5$: オブジェクトが存在するグリッドセルに対するbboxの座標誤差の重み。objが存在するセルの重みが増加。
- $\lambda_{\text{noobj}} = 0.5$: オブジェクトが存在しないグリッドセルに対する信頼度スコアの誤差の重み。
- $1_{\text{obj}_{ij}}, 1_{\text{noobj}_{ij}}$: グリッドセルi列j番目のバウンディングボックスがオブジェクトを含むかどうかを示す関数。[0, 1]
- x_i, y_i, w_i, h_i : 真のバウンディングボックスの座標とサイズ。
- $\hat{x}_i, \hat{y}_i, \hat{w}_i, \hat{h}_i$: 予測されたバウンディングボックスの座標とサイズ。
- C_i : 真の信頼度スコア。
- $\hat{C}_i$: 予測された信頼度スコア。
- $p_i(c)$: 真のクラス確率。
- $\hat{p}_i(c)$: 予測されたクラス確率。

YOLOの学習

信頼度スコア

$\text{Pr}(\text{Object}) \times \text{IOU}$ で、バウンディングボックス内にオブジェクトが存在するかどうかの確率を示す。

- $\text{Pr}(\text{Object})$: オブジェクトが存在する確率
- IOU : 予測bboxと実際のbboxの重なり具合

パラメータ

- エポック数: 135
- バッチサイズ: 64
- モメンタム: 0.9
- 減衰率 (Weight Decay) : 0.0005

学習率

- 初期学習率: $(1e-2)$ (Epoch 1~75)
- 第1ステップ学習率: $(1e-3)$ (Epoch 76~105)
- 第2ステップ学習率: $(1e-4)$ (Epoch 106~135)

YOLOの学習

過学習の防止

- **ドロップアウト：**
 - **適用場所:** 最初の全結合層の後。
 - **ドロップアウト率:** 0.5。
- **データ拡張：**
 1. **ランダムスケーリング:**
 - 入力画像のサイズを20%以内でランダムに変更。
 2. **色調調整 (Color Jittering)：**
 - 画像の露出や彩度を最大1.5倍まででランダムに調整。

YOLOの学習

予測の割り当て (Assigning Responsibility to Predictors)

- 設定:
 - グリッドセル内に1つの物体（例: 人）が存在する。
 - 各グリッドセルに2つの予測器（ $B=2$ ）が存在する。
- 予測器のIOU計算:
 - 予測器1: $\text{IOU} = 0.6$
 - 予測器2: $\text{IOU} = 0.4$
- 責任の割り当て:
 - 予測器1が最も高いIOU（0.6）を持つため、この予測器に責任を割り当てる。
 - 予測器2には責任が割り当てられず、信頼度スコアの誤差のみが損失関数に反映される。

例えばbboxの数が2つで、検出対象が3種類以上(人、車、自転車など)あった場合、3つ目の物体については学習されない。(YOLOの制限)

YOLOの推論

推論

1. ドロップアウトの無効化
2. データ拡張の無効化
3. 非最大抑制(NMS)の適用
信頼度スコアの高いbboxから順番に、bbox同士を比較していき、IOUが一定の閾値を超えた場合、信頼度スコアの低いbboxを削除する(bboxの重複回避)

制約

- ・近接物体
各グリッドセルが2つのバウンディングボックスのみを使用し、予測はセル毎に1つのクラスに限定されるため、近接する複数の物体の検出が難しい。
- ・細かい特徴の把握
ネットワークのダウンサンプリング層が多いため、細かい特徴を捉える能力が低い。

- YOLO(初代)とは
- YOLOの学習と推論
- **他手法との比較**

比較

PASCAL VOC 2007における性能


- YOLO :
45 FPS(Frames per second) で
63.4% mAP(mean Average Precision)
- Fast YOLO:
155 FPS で 52.7% mAP
- Fast R-CNN :
0.5 FPS で 70.0% mAP

エラー分析

- Correct: クラスが正しい。IOU > 0.5
- Localization: クラスが正しい。0.1 < IOU < 0.5
- Similar: クラスが類似、IOU > 0.1
- Other: クラスが間違っている、IOU > 0.1
- Background: 任意のオブジェクトに対して IOU < 0.1

Fast R-CNN は正解率が高いが、locを含めるとYOLO は精度で上回る。


Real-Time Detectors	Train	mAP	FPS
100Hz DPM [31]	2007	16.0	100
30Hz DPM [31]	2007	26.1	30
Fast YOLO	2007+2012	52.7	155
YOLO	2007+2012	63.4	45
Less Than Real-Time			
Fastest DPM [38]	2007	30.4	15
R-CNN Minus R [20]	2007	53.5	6
Fast R-CNN [14]	2007+2012	70.0	0.5
Faster R-CNN VGG-16[28]	2007+2012	73.2	7
Faster R-CNN ZF [28]	2007+2012	62.1	18
YOLO VGG-16	2007+2012	66.4	21



比較

未知のデータに対する性能

未知のPicasso and People-art dataset
でも他手法に対して良い性能を示す。




(a) Picasso Dataset precision-recall curves.

	VOC 2007 AP	Picasso AP	Picasso Best F_1	People-Art AP
YOLO	59.2	53.3	0.590	45
R-CNN	54.2	10.4	0.226	26
DPM	43.2	37.8	0.458	32
Poselets [2]	36.5	17.8	0.271	
D&T [4]	-	1.9	0.051	

(b) Quantitative results on the VOC 2007, Picasso, and People-Art Datasets. The Picasso Dataset evaluates on both AP and best F_1 score.

Figure 5: Generalization results on Picasso and People-Art datasets.



YOLO(初代)とは

24+2層の単一ニューラルネットワークで、画像全体からbboxの座標やクラス確率を一度に予測するモデル。

リアルタイム処理向けに開発されたため処理が高速であり、一般化能力が向上している。

