

論文紹介 2026/06/06

Attention is all you need

所属未入力

発表者未入力

■ アジェンダ

- 研究背景と課題
- 提案モデル「Transformer」
- Self-Attentionの優位性
- 実験設定と結果
- 考察と今後の展望
- まとめ

— 研究背景と課題

系列変換モデルはRNN・CNNベースが主流

- **従来の主流モデル**

- 複雑なリカレントまたは畳み込みニューラルネットワークに基づく。
- 最も性能の良いモデルはEncoder-Decoder間にAttentionメカニズムを導入。

- **課題**

- 計算が入力と出力のシンボル位置に沿って展開されるため、本質的にシーケンシャルな処理になる。
- このシーケンシャルな性質が並列化を妨げ、特に長い系列では訓練時間が課題となる。

— 解決したい課題

Attentionは一般的だがRNNとの併用が前提だった

- **Attentionメカニズムの現状**

- 多くの系列変換モデルに不可欠な要素となっている。
- 入力・出力系列における距離に関わらず依存関係をモデル化できる。
- しかし、ほとんどの場合、RNNと組み合わせて使用される。

- **本研究の目的**

- リカレントや畳み込みを完全に廃止し、Attentionメカニズムのみに基づく新しいネットワークアーキテクチャ「Transformer」を提案する。
- これにより、より高い並列化と、大幅な訓練時間の短縮を目指す。

— 提案モデル「Transformer」

Attentionのみで構成されるEncoder-Decoderモデル

リカレントや畳み込みを排除し、Attention
メカニズムのみで構成。

[図: Transformerのモデル全体像 (Figure 1)]

※EncoderとDecoderの全体像

- ****Encoder****
 - N個の同一層を積み重ねた構造。
 - 各層はMulti-Head Self-AttentionとPosition-wise Feed-Forward Networkから成る。
- ****Decoder****
 - N個の同一層を積み重ねた構造。
 - Encoder出力へのMulti-Head Attention層が追加。
 - Self-Attention層は未来の位置への

— Scaled Dot-Product Attention

Query, Key, Valueを用いて重み付き和を算出

- **基本的なAttention関数**

- クエリ (Query) と、キー (Key) -バリュー (Value) のペアセットを入力とする。
- クエリと対応するキーの適合度から、各バリューの重みを計算し、その重み付き和を出力とする。

- **Scaled Dot-Product Attention**

- クエリとキーの内積を計算し、 $\sqrt{d_k}$ でスケーリング。
- Softmax関数で重みを得て、バリューの重み付き和を計算。
- d_k が大きいと内積も大きくなり、Softmax勾配が小さくなるのを防ぐためスケーリングが重要。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

— Multi-Head Attention

複数のAttentionを並列実行し、異なる側面を捉える

- **単一Attentionの限界**

- 単一のAttention関数では、異なる表現部分空間からの情報を捉えることが難しい。

- **Multi-Head Attentionの仕組み**

- クエリ、キー、バリューを異なる学習済み線形射影で h 回並列に変換。
- 各射影版に対してAttention関数を並列に実行（Attention Head）。
- 各Headの出力を結合し、再度線形射影して最終結果を得る。
- 本研究では $h = 8$ 個のHeadを使用。これにより、モデルは異なる位置や表現部分空間からの情報に共同で注目可能になる。

[図: Scaled Dot-Product AttentionとMulti-Head Attentionの図（Figure 2）]

※複数のAttention Headが並列に動作する様子

— Position-wise Feed-Forward Networks

各位置に独立して適用されるフィードフォワードネットワーク

- **構成**

- 各Encoder・Decoder層にAttentionサブ層に加えて含まれる。
- 2つの線形変換とReLU活性化関数で構成される。
- $\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$

- **特徴**

- 各位置に全く同じネットワークが独立して適用される。
- 各層で異なるパラメータを持つ。
- 入出力次元は $d_{\text{model}} = 512$ 、内部層は $d_{\text{ff}} = 2048$ 。

— 位置エンコーディング

系列の順序情報をモデルに注入

- **なぜ必要か**

- Transformerはリカレントや畳み込みを含まないため、系列の順序情報を直接扱えない。
- モデルが入力系列の各トークンの絶対的または相対的な位置を利用できるようにする必要がある。

- **手法**

- 入力埋め込みに「位置エンコーディング」を加算する。
- 埋め込みと同じ d_{model} 次元を持つ。
- 本研究では異なる周波数のサイン・コサイン関数を使用。

$$P E_{(\text{pos}, 2i)} = \sin(\text{pos}/10000^{2i/d_{\text{model}}})$$

$$P E_{(\text{pos}, 2i+1)} = \cos(\text{pos}/10000^{2i/d_{\text{model}}})$$

- **利点**

— なぜSelf-Attentionか

高い並列性、短いパス長、少ない計算量

1. 各層の計算量

- Self-Attention: $O(n^2 \cdot d)$
- Recurrent: $O(n \cdot d^2)$
- Convolutional: $O(k \cdot n \cdot d^2)$
- $n < d$ の場合、Self-Attentionが Recurrentより高速。

2. 並列化の可能性

- Self-Attention: $O(1)$ の逐次操作で全位置を接続。
- Recurrent: $O(n)$ の逐次操作が必要。

3. 長距離依存関係のパス長

- Self-Attention: $O(1)$ (全ての入力・出力位置間で一定)
- Recurrent: $O(n)$
- Convolutional: $O(\log_k(n))$
- パス長が短いほど、長距離依存関係の学習が容易。

副次的な利点

- Attentionの分布から、モデルの解釈性が向上する。
- 構文・意味構造に関連する振る舞いを各Headが学習。

— 実験設定

WMTデータセットと効率的な訓練戦略

- **データセット**

- WMT 2014 English-German (約450万文ペア)
- WMT 2014 English-French (約3600万文ペア)
- Byte-Pair Encoding (BPE) または Word-Pieceを使用。

- **ハードウェアと訓練時間**

- NVIDIA P100 GPU 8基搭載マシンを使用。
- Baseモデル: 12時間で10万ステップ。
- Bigモデル: 3.5日間で30万ステップ。

- **最適化と正則化**

- Adam Optimizerを使用。
- 学習率スケジューリング:ウォームアップ後にステップ数に応じ減衰。
- Residual DropoutとLabel Smoothingを適用。

— 結果 (機械翻訳)

既存モデルを大きく上回るBLEUスコアを達成

- **WMT 2014 English-to-German**

- Transformer (big): **28.4 BLEU** (新SOTA)
 - 既存の最高結果（アンサンブル含む）を2.0 BLEU以上上回る。
- Transformer (base): **27.3 BLEU**
 - 既存の全ての公開モデル・アンサンブルを上回る。

- **WMT 2014 English-to-French**

- Transformer (big): **41.8 BLEU** (単一モデル新SOTA)
 - 既存SOTAの1/4以下の訓練コストで達成。

- **訓練効率**

- 訓練コスト（FLOPs）も既存モデルと比較して大幅に削減。

[図: Table 2 (BLEUスコアと訓練コストの比較)]

— 結果 (構文解析)

他のタスクへの汎用性も確認

- **English Constituency Parsing**

- Transformer (4層) を適用し、WSJデータセットで評価。
- タスク固有の調整なしで、驚くべき性能を発揮。
- **WSJのみ学習の場合**: 91.3 F1
- **半教師あり学習の場合**: 92.7 F1

- **既存モデルとの比較**

- ほとんどの先行モデル (RNN系列変換モデルなど) より良い結果。
- 制限された訓練データ (4万文) でも、Berkeley-Parserなどを上回る。

- **結論**

- Transformerが機械翻訳以外のタスクにも、高い汎用性を持つことを示した。

[図: Table 4 (構文解析タスクでのF1スコア比較)]

— 考察と今後の展望

Attentionベースモデルの可能性

- **Attentionの解釈性**

- Attentionの分布を分析することで、モデルが構文的・意味的な構造に関連する振る舞いを学習していることが示唆された。

- **今後の展望**

- Transformerをテキスト以外の入力・出力モダリティ（画像、音声、動画など）を含む問題へ適用。
- ローカルで制限されたAttentionメカニズムの検討により、大規模な入力・出力を効率的に処理。
- 生成をより非シーケンシャルにする研究目標。

— まとめ

Attentionのみで構成される画期的なモデル

- **Transformerの提案**

- リカレント層や畳み込み層を排除し、Multi-Head Self-Attentionのみで構成される初の系列変換モデル。

- **SOTAの達成と効率性**

- WMT 2014 English-to-GermanおよびEnglish-to-French翻訳タスクで新たなSOTAを達成。
- 既存のRNN/CNNベースのモデルと比較して、訓練速度と並列化性能が大幅に向上。

- **高い汎用性**

- 英語構文解析タスクにおいても優れた性能を示し、様々なタスクへの適用可能性を実証。