

論文紹介 2026/06/18

Attention is all you need

所属未入力

発表者未入力

■ アジェンダ

- 1. 研究背景と課題
- 2. 提案モデル: Transformerの全体像
- 3. Attentionメカニズムの詳細
- 4. 実験設定と結果
- 5. モデルの利点と考察
- 6. まとめ

— 1. 研究背景と課題

従来の系列変換モデルは並列化に課題

- **従来のモデル:**

- RNNs, LSTMs, Gated Recurrent Networksが主流
- Encoder-Decoderアーキテクチャが一般的
- EncoderとDecoderをAttentionで接続し性能向上

- **課題:**

- 計算が入力・出力のシンボル位置に沿って逐次的に行われる
- 長い系列では並列化が困難
- 長距離依存関係の学習も課題

— 2. 提案モデル: Transformerの全体像


Attentionメカニズムのみで構成された新しいアーキテクチャ

- **Transformerの概要:**

- 再帰層や畳み込み層を完全に排除
- Attentionメカニズムのみでグローバルな依存関係を捕捉
- 高い並列化が可能

- **モデル構造:**

- EncoderとDecoderから成る
- それぞれ複数の同一層が積み重ねられている
- 残差接続と層正規化を使用



— 3. Attentionメカニズムの詳細

クエリ、キー、値を用いた重み付き和を計算

- **Scaled Dot-Product Attention:**

- クエリ (Q)、キー (K)、値 (V) を入力
- 出力はQとKの内積をスケールし、ソフトマックス関数を通してVの重み付き和を算出
- 次元 d_k でスケールすることで、大きな値の内積がソフトマックスを飽和させるのを防ぐ

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

- **Multi-Head Attention:**

- 複数のAttention関数を並列に実行
- それぞれのヘッドで異なる表現部分空間に注目できる
- 複数のヘッドの出力を結合し、線形変換

— 3. Attentionメカニズムの詳細 (続き)

Multi-Head Attentionの適用箇所

- **Encoder-Decoder Attention:**
 - Decoderからのクエリ、Encoderからのキーと値
 - Decoderが入力系列全体に注目することを可能にする
- **EncoderのSelf-Attention:**
 - 全てのクエリ、キー、値がEncoderの前の層の出力から供給
 - Encoder内の各位置が、Encoderの前の層の全位置に注目できる
- **DecoderのSelf-Attention:**
 - Decoder内の各位置が、その位置以前のDecoder位置に注目
 - 自己回帰性を保つため、将来の位置への情報流をマスク

— 3. Position-wise Feed-Forward Networks

Attention層に加えて各層に導入

- **構成:**

- 2つの線形変換とReLU活性化関数から成る
- 各位置に独立して同一のネットワークを適用

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

- **特徴:**

- 異なる位置間で同じパラメータを共有
- カーネルサイズ1の2つの畳み込みと解釈できる
- 入出力次元 $d_{\text{model}} = 512$
- 内層次元 $d_{\text{ff}} = 2048$

— 3. Positional Encoding

逐次処理や畳み込みがないモデルの課題解決

- **必要性:**

- モデルが系列の順序を利用できない課題
- 入力埋め込みと位置エンコーディングを単純に加算

- **手法:**

- 異なる周波数のサイン関数とコサイン関数を使用

$$\begin{aligned}PE_{(pos, 2i)} &= \sin(pos/10000^{2i/d_{model}}) \\PE_{(pos, 2i+1)} &= \cos(pos/10000^{2i/d_{model}})\end{aligned}$$

- `pos` は位置、`i` は次元
- 学習可能な位置埋め込みと比較し、ほぼ同等の結果
- 訓練時に遭遇するよりも長い系列への外挿に有利と仮定

— 4. 実験設定と結果

機械翻訳タスクで性能を評価

- **データセット:**

- WMT 2014 英独翻訳: 約450万文
- WMT 2014 英仏翻訳: 約3600万文

- **学習:**

- 8基のNVIDIA P100 GPUを使用
- Baseモデルは12時間、Bigモデルは3.5日で学習
- Adamオプティマイザ、学習率スケジューリング、Dropout、Label Smoothingを使用

— 4. 実験設定と結果 (続き)

Transformerが両タスクでSoTAを達成

- **英独翻訳 (WMT 2014):**
 - **Transformer (big):** BLEU 28.4 を達成
 - 既存の最高記録（アンサンブル含む）を 2.0 BLEU以上 上回る
- **英仏翻訳 (WMT 2014):**
 - **Transformer (big):** BLEU 41.8 を達成
 - 既存の最高記録（単一モデル）を上回り、訓練コストも大幅に削減
- **訓練コスト:**
 - 既存モデルよりも桁違いに少ないFLOPSで高性能を実現

— 5. モデルの利点と考察

Attention層の特性とTransformerの優位性

- **計算複雑度:**
 - Self-Attention層はRecurrent層よりも低コスト ($O(n^2 \cdot d)$ vs $O(n \cdot d^2)$)
- **並列化:**
 - Self-Attentionは定数の逐次操作で全位置を接続
 - Recurrent層は $O(n)$ の逐次操作が必要
- **パス長:**
 - Self-Attentionは長距離依存関係のパス長が **定数** ($O(1)$)
 - Recurrent層やConvolutional層よりも短く、学習が容易

— 5. モデルの利点と考察 (続き)

モデルバリエーションからの知見

- **Attention Head数:**
 - 最適なヘッド数があり、単一ヘッドや多すぎるヘッドでは性能が低下
- **キー次元 (d_k):**
 - キー次元の削減はモデル品質を損なう
 - 互換性決定の難しさを示唆
- **モデルサイズ:**
 - 一般的に、より大きなモデルが良い性能を示す
- **Dropout:**
 - 過学習を防ぐ上で非常に有効
- **Positional Encoding:**
 - 学習済み埋め込みとサイン波埋め込みでほぼ同等の結果

— 5. 他のタスクへの適用

英語構文解析タスクでの成功

- **タスクの課題:**
 - 出力に強い構造的制約がある
 - 入力より出力が著しく長い場合がある
 - 少量の訓練データではRNNsがState-of-the-Artを達成できていなかった
- **Transformerの成果:**
 - WSJデータセット（4万文）のみの学習で高精度を達成
 - 半教師あり学習設定でも優れた性能を示し、多くの既存モデルを凌駕
 - タスク固有の調整なしに良好な汎化性能を発揮

— 6. まとめ

AttentionのみのTransformerが新たな標準へ

- **Transformerの貢献:**

- 再帰・畳み込み層を廃し、Attentionのみで系列変換を可能にした初のモデル
- 機械翻訳タスクでState-of-the-ArtのBLEUスコアを達成し、訓練時間も大幅に短縮
- 英語構文解析のような異なるタスクでも優れた汎化性能を発揮

- **今後の展望:**

- Attentionベースモデルのさらなる応用
- 画像や音声など、他のモダリティへの拡張
- 生成プロセスの非逐次化

