

論文紹介 2026/06/27

CNN

理学部 化学科

知能 太郎

■ アジェンダ

- ANNとCNNの背景
- 従来のANNの課題
- CNNの基本構成
- 畳み込み層の詳細
- その他の主要層
- CNNの設計指針
- 学習結果の可視化
- まとめ

— ANNの台頭とCNN

機械学習分野で人工ニューラルネットワーク（ANN）が顕著な成果を上げている。

- **ANNの進化:** 近年、従来のAI性能を凌駕するモデルが登場している。
- **CNNの重要性:** 特に画像認識タスクにおいて、畳み込みニューラルネットワーク（CNN）は非常に高い性能を示す。
- **生物学的着想:** CNNは生物の視覚野から着想を得ており、画像処理に特化したアーキテクチャを持つ。
- **学習の容易さ:** その構造は精密かつシンプルであり、ANN入門に適している。

— 従来のANNの課題

従来の全結合型ANNは画像データ処理において計算コストと過学習の問題を抱える。

- **高解像度画像の計算コスト:**
 - 入力画像のサイズが増大すると、ANNのパラメータ数も爆発的に増加する。
 - 例: 64x64x3のカラー画像の場合、最初の隠れ層のニューロン1つあたり12,288個の重みが必要となる。
- **過学習のリスク増大:**
 - 過剰なパラメータは、訓練データへの過度な適合（過学習）を引き起こし、汎化能力を低下させる。
- **CNN知識の普及:**
 - CNNは強力だが、その仕組みが複雑に見えるため、初学者の学習障壁が高い傾向にある。

— CNNの全体像

CNNは画像データに特化し、主に3種類の層を積み重ねて構成される。

- **畳み込み層 (Convolutional Layer)**:
 - 局所的な特徴を抽出する
- **プーリング層 (Pooling Layer)**:
 - 特徴マップの次元を削減する
- **全結合層 (Fully-connected Layer)**:
 - 最終的な分類や回帰を行う

[図: 図2のシンプルなCNNアーキテクチャを入れる] シンプルなCNNアーキテクチャの例

— 畳み込み層の詳細

畳み込み層は、学習可能なカーネルを用いて画像から局所的な特徴を効率的に抽出する。

- **特徴抽出:** 学習可能な**カーネル（フィルタ）**で入力画像からエッジなどの局所特徴を抽出する。
- **局所的結合:** 各ニューロンは前の層の小さな領域（**受容野**）にのみ接続する。
- **パラメータ共有:** 同じカーネルを画像全体に適用することで、パラメータ数を大幅に削減する。
- **活性化関数:** 一般的に**ReLU (Rectified Linear Unit)**が使用される。

[図: 図4の畳み込み演算の図解を入れる]

畳み込み演算の図解

— その他の主要層：プーリング層と全結合層

畳み込み層で抽出された特徴は、プーリング層で集約され、最終的に全結合層で分類される。

- **プーリング層:**
 - 特徴マップの空間的次元を削減し、計算負荷を軽減する。
 - **Max-pooling:** 局所領域の最大値を抽出し、微小な位置ずれに対する頑健性（位置不変性）を付与する。
 - 一般的に2x2のカーネルと2のストライドが使用される。
- **全結合層:**
 - 畳み込み層とプーリング層で学習された高レベルの特徴を統合する。
 - 最終的な分類スコアや回帰値を出力する層であり、従来のANNと同様の役割を果たす。

— CNNの構造設計とパラメータ削減

CNNの出力ボリュームの次元は、ハイパーパラメータによって調整される。

- 主要なハイパーパラメータ:
 - 深さ (Depth): 出力ボリュームの深さ (特徴マップの枚数)。
 - ストライド (Stride): カーネルが移動するステップサイズ。
 - ゼロパディング (Zero-padding): 入力画像の周囲にゼロを追加し、出力サイズを制御する。

- 出力ボリュームサイズの計算式:

$$\frac{(V - R + 2Z)}{S} + 1$$

- V: 入力ボリュームサイズ (高さまたは幅)
 - R: 受容野サイズ (カーネルサイズ)
 - Z: ゼロパディング量
 - S: ストライド
- 一般的なアーキテクチャ: 畳み込み層とプーリング層を交互に重ね、最後に全結合層を配置する。

— 学習結果の可視化

CNNは、訓練データから自動的に有用な特徴を階層的に学習する。

- **特徴の自動学習:** CNNは入力画像から低レベル（エッジ）から高レベル（物体の一部）の特徴までを自動で学習する。
- **フィルタのアクティベーション:** MNISTデータセットで訓練されたCNNの最初の畳み込み層のアクティベーションを可視化できる。
- **学習内容の把握:** この可視化により、ネットワークが数字特有のエッジやストロークといった基本的な視覚的特徴を捉えていることがわかる。

[図: 図3の学習済みフィルタの可視化（MNISTのアクティベーション）を入れる]

畳み込み層が学習した特徴の可視化 (MNIST)

— まとめ

CNNは画像データの特性を活かし、効率的な特徴学習と高精度な分類を可能にする。

- **CNNの利点:** 従来のANNが抱えるパラメータ数の問題と過学習のリスクを、画像の局所性を利用することで克服する。
- **主要構成要素:** 畳み込み層（特徴抽出）、プーリング層（次元削減）、全結合層（分類）が連携して機能する。
- **効率的な学習:** パラメータ共有や局所的結合により、少ないパラメータで効率的な学習を実現する。
- **普及への貢献:** 本論文はCNNの基本概念と設計指針を平易に解説し、この強力な技術の学習障壁を低減することを目指した。