

論文紹介 2026/06/27

CNN

理学部 化学科

知能 太郎

■ アジェンダ

- CNNの概要
- 従来のANNが抱える課題
- CNNの基本アーキテクチャ
- 各層の詳細：畳み込み層
- 各層の詳細：プーリング層と全結合層
- CNN設計のポイントとまとめ

— 研究背景：機械学習とANNの台頭

近年、機械学習分野では人工ニューラルネットワーク（ANN）が優れた成果を上げている。

- ANNは従来のAI技術を凌駕する性能を示す
- 特に畳み込みニューラルネットワーク（CNN）が画像認識タスクで目覚ましい
- CNNは生物の視覚野から着想を得たアーキテクチャである
- その構造は精密でありながらシンプルであるため、ANN入門に適する

— 従来のANNが抱える課題

全結合型のANNは、画像データ処理において計算コストと過学習のリスクが高い。

- 計算複雑性の問題
 - MNIST (28x28) のモノクロ画像でも、初層1ニューロンで784個の重みが必要である
 - 64x64のカラー画像では、初層1ニューロンで12,288個もの重みが必要となる
- 過学習 (Overfitting) の問題
 - パラメータ数が膨大になると、モデルが訓練データに過度に適合し、未知のデータへの汎化能力が低下する
 - 大規模なANNを訓練するには、莫大な計算資源と時間が必要である

— CNNの全体像

CNNは入力データが画像であることを前提とし、その特性を活かしたアーキテクチャを持つ。

- 3種類の主要な層で構成される
 - 畳み込み層 (Convolutional Layer)：特徴を抽出する
 - プーリング層 (Pooling Layer)：次元を削減する
 - 全結合層 (Fully-connected Layer)：最終的な分類スコアを出力する
- これらの層を積み重ねることで、入力画像から階層的に特徴を抽出し、分類や回帰を行う
- [図: 図2のシンプルなCNNアーキテクチャ]

— CNNの核：畳み込み層の機能

畳み込み層は、学習可能なカーネル（フィルタ）を用いて入力画像から局所的な特徴を抽出する。

- **特徴抽出**：カーネルが入力画像をスライドし、局所領域の情報を集約し特徴マップを生成する
- **局所的結合 (Local Connectivity)**：ニューロンは前の層の小さな領域にのみ接続する
- **パラメータ共有 (Parameter Sharing)**：同じカーネルを画像全体で使い回す
- これにより、パラメータ数を劇的に削減し、過学習を抑制する
- [図: 図4の畳み込み演算の図解]

— 畳み込み層の制御：ハイパーパラメータ

畳み込み層の挙動は以下の3つのハイパーパラメータで調整される。

- 深さ (Depth)：出力ボリュームの層数であり、使用するカーネルの数に相当する
- ストライド (Stride)：カーネルが移動する際のステップサイズであり、出力の空間次元に影響を与える
- ゼロパディング (Zero-padding)：入力の境界をゼロで埋めることで、出力の空間次元を維持または調整する
- 出力サイズ計算式：

$$\frac{(V - R + 2Z)}{S} + 1$$

- V: 入力ボリュームサイズ (高さまたは幅)
- R: 受容野サイズ (カーネルサイズ)
- Z: ゼロパディング量
- S: ストライド

— プーリング層と全結合層

畳み込み層に続き、プーリング層と全結合層がネットワークの最終的な出力に貢献する。

- **プーリング層 (Pooling Layer)**
 - 特徴マップの空間次元を削減するダウンサンプリング層である
 - **Max-pooling**が一般的であり、特定の領域の最大値を取る
 - これにより、計算量を削減し、特徴の微小な位置ずれに対する頑健性（位置不変性）を向上させる
- **全結合層 (Fully-connected Layer)**
 - 畳み込み層とプーリング層で抽出された特徴を統合し、最終的な分類や回帰のスコアを出力する
 - これは従来のANNと同様の役割を果たす

— CNN設計のポイント

効率的で高性能なCNNを構築するためには、いくつかの設計原則がある。

- **層の積み重ね**：畳み込み層とプーリング層を交互に重ねるのが基本構造である
- **複数畳み込み層**：プーリング層の前に畳み込み層を複数（例：2層）重ねることで、より複雑な特徴を学習できる
- **小規模フィルタ**：一般的に小さなフィルタ（例：3x3）を使用し、ストライドは1に設定する
- **ゼロパディング**：空間次元を維持するため、適切な量のゼロパディングを使用する
- [図: 図5の複数の畳み込み層を持つCNNアーキテクチャ]

— 学習された特徴の可視化

CNNの畳み込み層は、学習によって入力画像から意味のある視覚的特徴を自動的に捉える。

- MNISTデータセットで訓練されたCNNの最初の畳み込み層のアクティベーションを可視化した例がある
- ネットワークは、数字の**エッジ**や**ストローク**など、特定の数字に固有の低レベルな視覚的特徴を成功裏に学習している
- これにより、CNNがどのように画像情報を処理しているか理解を深めることができる
- [図: 図3の学習済みフィルタの可視化]

— まとめ

CNNは、画像の特性を活かした効率的かつ強力なニューラルネットワークアーキテクチャである。

- **課題解決**：従来のANNが画像処理で抱える計算量と過学習の問題を、局所的結合、パラメータ共有、プーリングにより解決する
- **階層的学習**：畳み込み層とプーリング層を重ねることで、単純な特徴から複雑な特徴へと段階的に学習する
- **高い性能とアクセス性**：画像認識タスクにおいて優れた性能を発揮し、そのシンプルな構造は初学者にも理解しやすい

