

提供されたMarp MarkdownとレンダリングされたPDFを分析し、ご提示のルールに基づいて修正を検討しました。

1. **math_inside_html の問題:** スライド8の数式 $\frac{(V - R + 2Z)}{S} + 1$ は、現在のMarkdownではHTMLブロック内に記述されていません。箇条書きの項目としてMarkdown本文に直接記述されており、PDF上でも正しくレンダリングされています。Marp/KaTeXのレンダリング安定性に関する一般的な注意喚起の可能性も考えられますが、このMarkdownの範囲では、数式をHTMLタグ内に入れないというルールは守られているため、この点に関してMarkdownの修正は不要と判断しました。
2. **dense_slide の問題 (スライド9):** レンダリングされたPDFのスライド9を確認しましたが、箇条書きの項目が2点のみで、情報量が過多であるようには見えません。文字が見切れていたり、詰まっていたりする問題もありませんでした。「学習結果の可視化 (1/2)」というタイトルも考慮すると、情報が適切な量に収まっていると判断し、スライドを分割する必要はないと結論付けました。

marp: true
theme: kaira
size: 16:9
math: katex
highlight: github

理学部 化学科

知能 太郎

■ アジェンダ

- ANNとCNNの背景
- 従来のANNの課題
- CNNの基本構成
- 畳み込み層の詳細
- その他の主要層
- CNNの設計指針
- 学習結果の可視化
- まとめ

— ANNの台頭とCNN

機械学習分野で人工ニューラルネットワーク（ANN）が顕著な成果を上げている。

- **ANNの進化:** 近年、従来のAI性能を凌駕するモデルが登場している。
- **CNNの重要性:** 特に画像認識タスクにおいて、畳み込みニューラルネットワーク（CNN）は非常に高い性能を示す。
- **生物学的着想:** CNNは生物の視覚野から着想を得ており、画像処理に特化したアーキテクチャを持つ。
- **学習の容易さ:** その構造は精密かつシンプルであり、ANN入門に適している。

— 従来のANNの課題

従来の全結合型ANNは画像データ処理において計算コストと過学習の問題を抱える。

- **高解像度画像の計算コスト:**
 - 入力画像のサイズが増大すると、ANNのパラメータ数も爆発的に増加する。
 - 例: 64x64x3のカラー画像の場合、最初の隠れ層のニューロン1つあたり12,288個の重みが必要となる。
- **過学習のリスク増大:**
 - 過剰なパラメータは、訓練データへの過度な適合（過学習）を引き起こし、汎化能力を低下させる。
- **CNN知識の普及:**
 - CNNは強力だが、その仕組みが複雑に見えるため、初学者の学習障壁が高い傾向にある。

— CNNの全体像

CNNは画像データに特化し、主に3種類の層を積み重ねて構成される。

- **畳み込み層 (Convolutional Layer)**:
 - 局所的な特徴を抽出する
- **プーリング層 (Pooling Layer)**:
 - 特徴マップの次元を削減する
- **全結合層 (Fully-connected Layer)**:
 - 最終的な分類や回帰を行う

[ここに論文
— Figure
2を入れる]

シンプルなCNNアーキテクチャの例

— 畳み込み層の詳細

畳み込み層は、学習可能なカーネルを用いて画像から局所的な特徴を効率的に抽出する。

- **特徴抽出:** 学習可能な**カーネル（フィルタ）**で入力画像からエッジなどの局所特徴を抽出する。
- **局所的結合:** 各ニューロンは前の層の小さな領域（**受容野**）にのみ接続する。
- **パラメータ共有:** 同じカーネルを画像全体に適用することで、パラメータ数を大幅に削減する。
- **活性化関数:** 一般的に**ReLU (Rectified Linear Unit)**が使用される。

[ここに論文Figure 4を入れる]

畳み込み演算の図解

— その他の主要層：プーリング層と全結合層

畳み込み層で抽出された特徴は、プーリング層で集約され、最終的に全結合層で分類される。

- **プーリング層:**
 - 特徴マップの空間的次元を削減し、計算負荷を軽減する。
 - **Max-pooling:** 局所領域の最大値を抽出し、微小な位置ずれに対する頑健性（位置不変性）を付与する。
 - 一般的に2x2のカーネルと2のストライドが使用される。
- **全結合層:**
 - 畳み込み層とプーリング層で学習された高レベルの特徴を統合する。
 - 最終的な分類スコアや回帰値を出力する層であり、従来のANNと同様の役割を果たす。

— CNNの構造設計とパラメータ削減

CNNの出力ボリュームの次元は、ハイパーパラメータによって調整される。

- 主要なハイパーパラメータ:
 - 深さ (Depth): 出力ボリュームの深さ（特徴マップの枚数）。
 - ストライド (Stride): カーネルが移動するステップサイズ。
 - ゼロパディング (Zero-padding): 入力画像の周囲にゼロを追加し、出力サイズを制御する。

- 出力ボリュームサイズの計算式:

$$\frac{(V - R + 2Z)}{S} + 1$$

- V: 入力ボリュームサイズ (高さまたは幅)
 - R: 受容野サイズ (カーネルサイズ)
 - Z: ゼロパディング量
 - S: ストライド
- 一般的なアーキテクチャ: 畳み込み層とプーリング層を交互に重ね、最後に全結合層を配置する。

— 学習結果の可視化 (1/2)

CNNは、訓練データから自動的に有用な特徴を階層的に学習する。

- **特徴の自動学習:** CNNは入力画像から低レベル（エッジ）から高レベル（物体の一部）の特徴までを自動で学習する。
- **フィルタのアクティベーション:** MNISTデータセットで訓練されたCNNの最初の畳み込み層のアクティベーションを可視化できる。

— 学習結果の可視化 (2/2)

- 学習内容の把握: この可視化により、ネットワークが数字特有のエッジやストロークといった基本的な視覚的特徴を捉えていることがわかる。

[ここに論文Figure 3を入れる]

畳み込み層が学習した特徴の可視化 (MNIST)

— まとめ

CNNは画像データの特性を活かし、効率的な特徴学習と高精度な分類を可能にする。

- **CNNの利点:** 従来のANNが抱えるパラメータ数の問題と過学習のリスクを、画像の局所性を利用することで克服する。
- **主要構成要素:** 畳み込み層（特徴抽出）、プーリング層（次元削減）、全結合層（分類）が連携して機能する。
- **効率的な学習:** パラメータ共有や局所的結合により、少ないパラメータで効率的な学習を実現する。
- **普及への貢献:** 本論文はCNNの基本概念と設計指針を平易に解説し、この強力な技術の学習障壁を低減することを目指した。